SKT AI Fellowship 47|)



Language-Image Multi-modal Al 기술 연구

이정우 장서윤 장성현

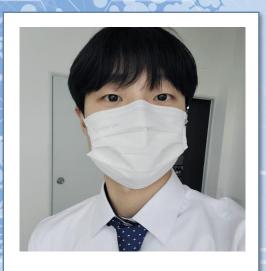
팀원 소개



이정우 성균관대 소프트융합대학 인공지능융합학과 석사과정



장서윤AI빅데이터융합경영학과/ 데이터사이언스연계융합전공



장성현AI빅데이터융합경영학과/ 데이터사이언스연계융합전공

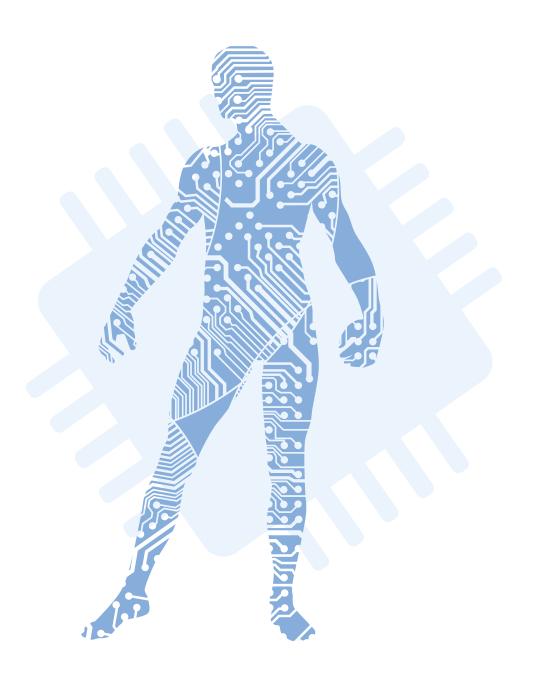
CONTENTS

01 연구 목표 최신 연구, 새로운 접근, 기존 한계점 보완, 성능 향상

O2 **연구 배경**Vision Language 분야의 발전 방향 Flamingo(04,2022)

O3 개선점 및 아이디어
Prompted learning
TCL

Data2vec









최신 연구 Vision-Language 분야의 최신 동향을 반영하는 연구

Vision-Language

Multi-modal Al



새로운 접근 최신 동향을 반영하면서도 새로운 접근법 제시



기존 한계점 보완 기존 방법론과 VL 분야에 존재하는 한계점 개선



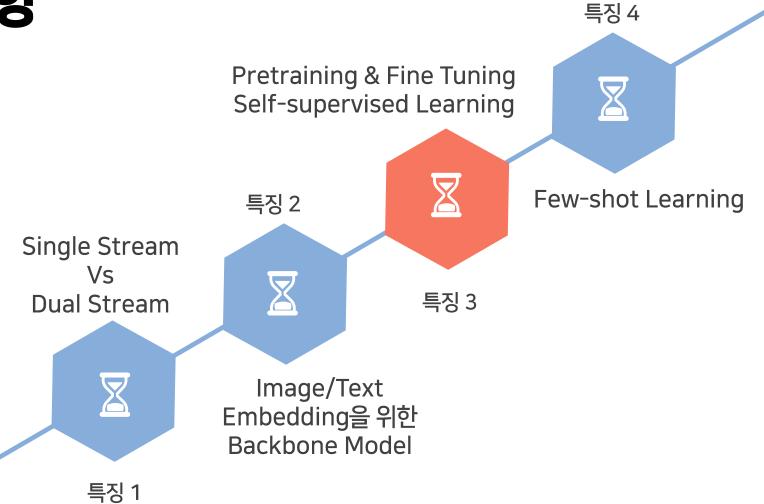
성능 향상 성능 개선 및 향상





Vision-Language 분야의 발전 방향

(2020~2022년) 최근 연구 동향

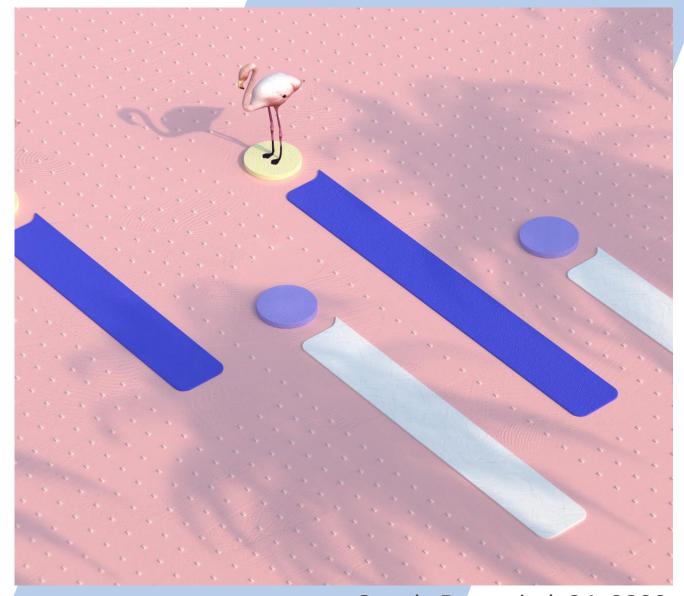


Flagminogo

A Visual Language for Few-Shot Learning

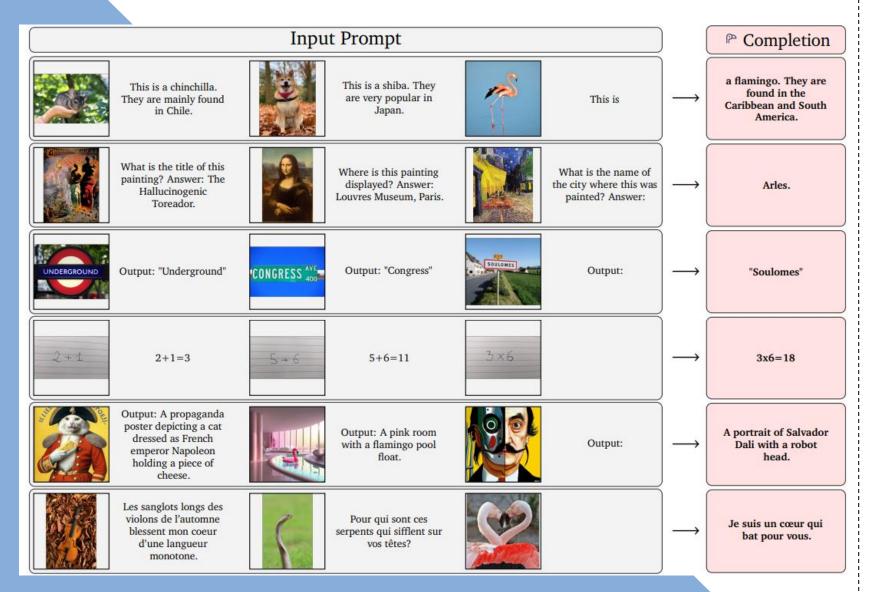
Contributions

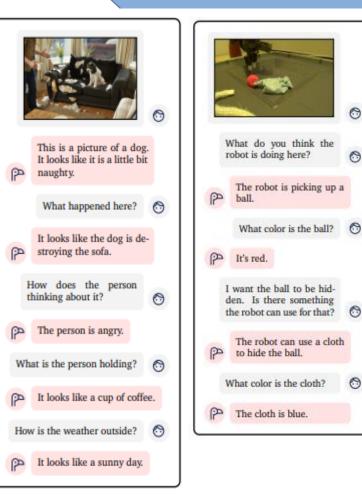
- 1. 임의로 interleaved된 이미지와 텍스트 데이터를 입력으로 받아들이고 open-ended 방식으로 출력 텍스트를 생성하기 위한 새로운 아키텍쳐
- 2. Pretrained 된 대규모 vision-only models와 Language-only models를 활용하여 초기 모델의 이점을 보존하면서도 효율적으로 융합하는 전략
- 3. 다양한 크기의 visual 입력에 효율적으로 적응하여 이미지 뿐만 아니라 비디오에도 적용 가능



Google Deepmind, 04. 2022

Flagminogo





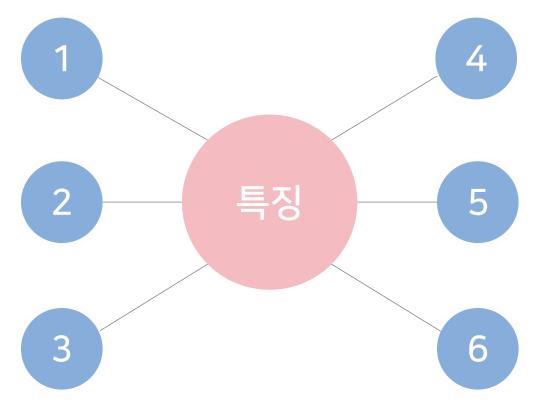


Flagminogo

Pretrained 된 model들을 활용해 해당 모델들의 이점을 활용

LMs(Large-Scale generative language models)로부터 영감을 받아서 general-purpose generation capabilities를 확보

Careful Mixtured 데이터셋

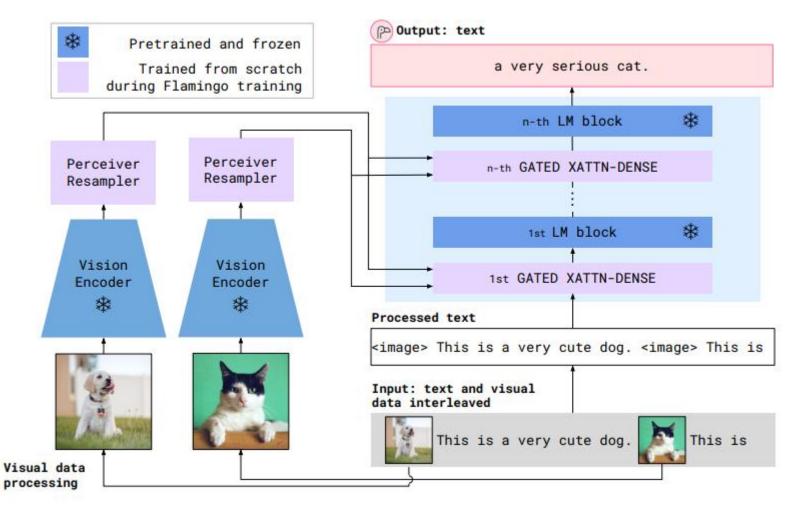


임의의 순서로 나열된 텍스트와 이미지로 이루어진 대규모 멀티 모달 웹 데이터로 학습

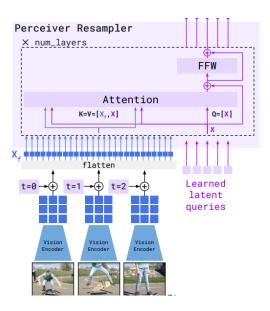
Perceiver-based architecture를 통해 고차원의 이미지, 비디오 데이터를 모두 처리 가능

두 개의 학습 가능한 components를 통해 vision-language side를 연결

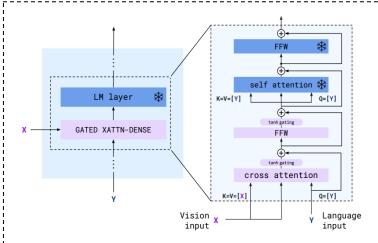
Architectures



▲ Overall Flow



▲ Vision Side Perceiver Resampler



▲ Language Side gated xattn -dense layers



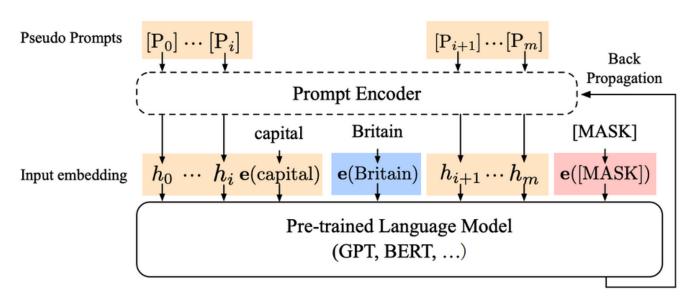
New Approach: P-tuning

매번 좋은 프롬프트를 바로바로 찾거나 직접 입력하는 것은 현실적으로 어려움

소량의 프롬프트로 미리 학습시킨 Prompt Encoder를 추가해보자 >> Automatically searching prompts

Only tunes continuous prompts

연속적인 공간에서 prompt-based learning을 수행하여 prompt 설계에 따라 성능이 불안정한 것을 개선



Vision-Language Pre-Training with Triple Contrastive Learning

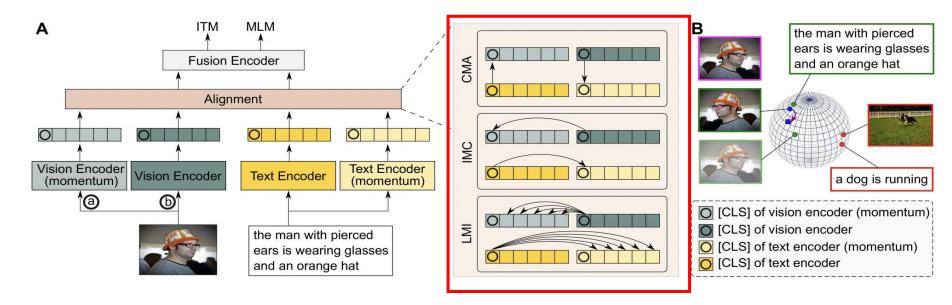
New Approach: TCL

Transformer 구조 사용으로 global한 feature들을 뽑는 데에만 유리 Local, structural한 정보를 고려하는 것을 실패

Loss function을 추가해보자



따라서 cross-modal뿐만 아니라 intra-modal의 의미 있는 정보를 학습, local한 information을 학습



New Approach: Data2vec

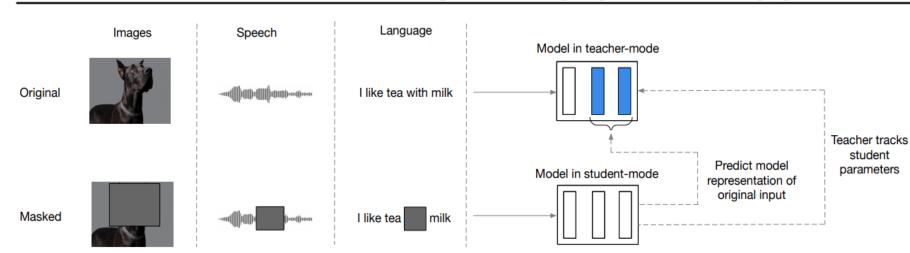
A General Framework for Self-supervised Learning in Speech, Vision and Language

하나의 architecture를 통해서 여러 도메인에 일반화된 성능으로 적용하는 방법론 Masked Input
with
Teacher-Student
self-distillation

Contextualized Representation Learning

encoder-decoder 구조를 Teacher-Student 구조로 대체해보자

data2vec: A General Framework for Self-supervised Learning in Speech, Vision and Language



참고자료

Flamingo: a Visual Language Model for Few-Shot Learning. 2022.

Vision-Language Pre-Training with Triple Contrastive Learning. 2022.

data2vec: A General Framework for Self-supervised Learning in Speech, Vision and Language. 2022.

GPT Understands, Too. 2021.

BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation. 2022.

CoCa: Contrastive Captioners are Image-Text Foundation Models. 2022.

PyramidCLIP: Hierarchical Feature Alignment for Vision-language Model Pretraining. 2022.

METER: An Empirical Study of Training End-to-End Vision-and-Language Transformers. 2021.

VLMo: Unified Vision-Language Pre-Training with Mixture-of-Modality-Experts. 2021.

MURAL: Multimodal, Multitask Retrieval Across Languages. 2021.

SimVLM: SIMPLE VISUAL LANGUAGE MODEL PRETRAINING WITH WEAK SUPERVISION. 2021.

Align before Fuse: Vision and Language Representation Learning with Momentum Distillation. 2021.

CLIP-ViL: How Much Can CLIP Benefit Vision-and-Language Tasks?. 2021.

Probing Inter-modality: Visual Parsing with Self-Attention for Vision-Language Pre-training. 2021.

E2E-VLP: End-to-End Vision-Language Pre-training Enhanced by Visual Learning. 2021.

SOHO: End-to-End Pre-training for Vision-Language Representation Learning. 2021.

MDETR: Modulated Detection for End-to-End Multi-Modal Understanding. 2021.

Kaleido-BERT: Vision-Language Pre-training on Fashion Domain. 2021.

ALIGN: Scaling Up Vision-Language Representation Learning with Noisy Text Supervision. 2021.

ViLT: Vision-and-Language Transformer Without Convolution or Region Supervision. 2021.

VL-T5: Unifying Vision-and-Language Tasks via Text Generation. 2021.

VinVL: Revisiting Visual Representations in Vision-Language Models. 2021.

RVL-BERT: Visual Relationship Detection with Visual-Linguistic Knowledge from Pre-trained Representations. 2021.

Oscar: Object-Semantics Aligned Pre-training for Vision-Language Tasks. 2020.

VILLA: A Generic Adversarial Training technique for Vision-and-Language. 2020.

